实验3-3 spark编程

0. scala安装

ubuntu: apt-get install scala 为了后面配置scala的环境变量,这里先找出scala的位置 通过which scala 可以查看到java的执行路径(不同于安装路径)

/usr/bin/scala

执行 Is -Irt /usr/bin/scala

执行 Is -Irt /etc/alternatives/scala, 其显示的/usr/share/scala-2.11就是我们需要查询的scala安装目录

```
root@h0:/home/Hadoop/spark-2.4.4/conf# ls -lrt /usr/bin/scala
lrwxrwxrwx 1 root root 23 Dec 3 00:13 /usr/bin/scala -> /etc/altern
atives/scala
root@h0:/home/Hadoop/spark-2.4.4/conf# ls -lrt /etc/alternatives/sca
la
lrwxrwxrwx 1 root root 31 Dec 3 00:13 /etc/alternatives/scala -> /u
sr/share/scala-2.11/bin/scala
```

1. spark安装

版本&环境: Ubuntu 18 + java 1.8 +hadoop-3.2.1 ,使用集群模式,两个节点h0和h1,h0作为master,仅有h1作为worker

spark使用hadoop的resourcemanager分配资源

下载,解压,配置相关文件见https://www.jianshu.com/p/a4a0e7e4e4b7

其中spark-env.sh配置见下图

```
#!/usr/bin/env bash
export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64
export SCALA_HOME=/usr/share/scala-2.11
export HADOOP_CONF_DIR=/home/Hadoop/hadoop-3.2.1/etc/hadoop
export HADOOP_HOME=/home/Hadoop/hadoop-3.2.1
#export HADOOP_HDFS_HOME=/usr/local/hadoop
export SPARK_HOME=/home/Hadoop/spark-2.4.4
export SPARK_MASTER_IP=h0
#export SPARK_MASTER_PORT=7077
export SPARK_MASTER_HOST=h0
#export SPARK_WORKER_PORT=8901
#export SPARK_WORKER_INSTANCES=1
export SPARK_MASTER_WEBUI_PORT=8080
```

start-all.sh

```
root@h0:/home/Hadoop/spark-2.4.4# jps
1248 Jps
355 NameNode
1190 Master
824 ResourceManager
574 SecondaryNameNode
```

```
root@h1:/home/Hadoop/spark-2.4.4# jps
24384 NodeManager
24274 DataNode
24582 Jps
23958 MainGenericRunner
24535 Worker
```

运行样例程序

```
root@h0:/home/Hadoop/spark-2.4.4# bin/run-example SparkPi 2>&1 |
p "Pi is"
Pi is roughly 3.1386956934784673
```

webUI



Spark Master at spark://h0:7077

URL: spark://h0:7077 Alive Workers: 1

Cores in use: 1 Total, 0 Used

Memory in use: 1024.0 MB Total, 0.0 B Used

Applications: 0 Running, 0 Completed Drivers: 0 Running, 0 Completed

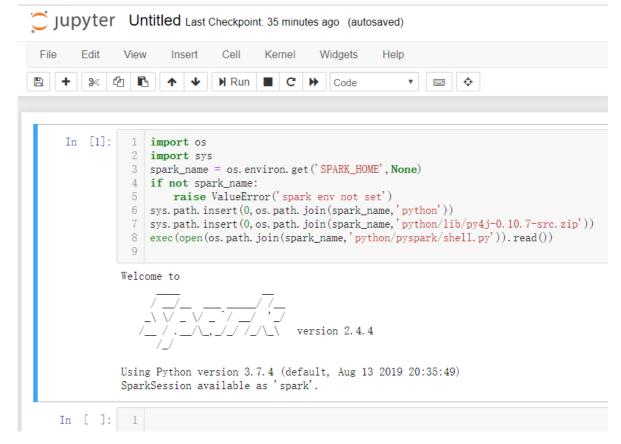
Status: ALIVE

2. spark编程实践

2.1 pyspark配置及使用

实验环境: 阿里云服务器, docker spark集群

- 安装anaconda, 并配置jupyter见教程https://www.jianshu.com/p/670486953d9e (因为是在 docker中配置,还需要在创建容器的时候配置端口映射,在阿里云安全组中开放对应的端口,关 闭防火墙)
- 配置jupyter的自动补全https://www.jianshu.com/p/0ab80f63af8a
- 运行jupyter,并在本机浏览器访问: xx.xx.xx.x:端口号 (注意使用chrome浏览器,默认edge不
- 配置pysparkhttps://blog.csdn.net/dxyna/article/details/79772343



下面就可以愉快的写代码啦

2.2 编程实践

• 统计各省销售最好的产品类别前十(每个省的数据中,第一个元素为商品类别,第二个是统计购买量)

```
rootship://home/ladoop/share-files/spark local_outputf cat out1/*
(*天津市*, [(1288*, 128), (*656*, 116), (*652*, 83), (*672*, 88), (*662*, 82), (*1142*, 88), (*389*, 75), (*737*, 74), (*177*, 71), (*664*, 67)])
(*福建*, [(*1288*, 128), (*656*, 116), (*662*, 83), (*177*, 88), (*662*, 76), (*1213*, 72), (*184*, 71), (*1401*, 67), (*737*, 64)])
(*山西*, [(*656*, 125), (*628*, 189), (*1288*, 189), (*1401*, 83), (*622*, 78), (*1213*, 76), (*1601*, 75), (*1612*, 73), (*428*, 73), (*389*, 73)])
(*土海市*, [(*656*, 125), (*662*, 188), (*1288*, 189), (*1142*, 83), (*127*, 88), (*1213*, 76), (*1401*, 75), (*622*, 75), (*137*, 73), (*389*, 72)])
(*岩港*, [(*656*, 124), (*1288*, 118), (*662*, 187), (*1142*, 83), (*132*, 83), (*127*, 88), (*622*, 68), (*1401*, 67), (*1141*, 68), (*428*, 65)])
(*岩港*, [(*656*, 124), (*1288*, 118), (*662*, 111), (*1213*, 84), (*1389*, 79), (*662*, 77), (*1737*, 72), (*1401*, 78), (*1142*, 63), (*429*, 65)])
(*芳港*, [(*1288*, 128), (*656*, 119), (*662*, 111), (*1213*, 84), (*1389*, 79), (*662*, 77), (*664*, 68), (*121*, 78), (*1389*, 72)])
(*安港*, [(*656*, 124), (*1288*, 128), (*652*, 181), (*673*, 88), (*1213*, 84), (*1481*, 88), (*662*, 88), (*128*, 88), (*128*, 88), (*1288*, 88), (*1288*, 88), (*1213*, 84), (*1481*, 88), (*652*, 77), (*664*, 68), (*429*, 67), (*1412*, 68)])
(*密門*, [(*656*, 128), (*1288*, 126), (*652*, 181), (*737*, 98), (*612*, 88), (*1213*, 78), (*1142*, 78), (*1387*, 78), (*1401*, 78), (*389*, 67)])
(*密門*, [(*656*, 128), (*1288*, 126), (*652*, 188), (*127*, 88), (*127*, 88), (*1142*, 78), (*1414*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (*1491*, 78), (
```

```
data=sc.textFile('file:///home/Hadoop/share-files/million_user_log.csv')#transform 类操作
#Spark每次作行动操作时,都是从最初的转化操作开始计算;如果不想从头开始计算,想保存中间结果表,就应该把数据载入缓存
data.cache()#相当于 .persist(MEMORY_ONLY) 将数据缓存存内存中
print(data.count())#count()为action类操作立即执行
print(data.first())
data=data.map(lambda x: list(x.split(',')))
```

```
data=data.filter(lambda x: x[7]=='2')
print(data.first())
data=data.map(lambda x: (x[10],x[2]))
print(data.first())
data=data.groupByKey()# 返回[(key,pyspark.resultiteratable),(,)]
data=data.mapValues(list)
#print(data.first())
def cat_10 (x):
   dct={}
    for key in x:
       dct[key]=dct.get(key,0)+1
    lst=sorted(dct.items(),key=lambda y:y[1],reverse=True)
    return lst[:10]
data=data.mapValues(cat_10)
print(data.first())
data.saveAsTextFile('file:///home/Hadoop/share-files/spark_local_output/out2')
#这里结果保存在本地,也可以选择saveAsHadoopData等保存在hdfs上
```

• 统计各省的双十一前十热门销售产品(购买最多前10的产品)--和MapReduce作业对比结果

代码同上一题, 只需把(x[10],x[2]) 替换为(x[10],x[1])即可

与mapreduce对比

```
n trust check: loc
上海市,191499 12
上海市,353560 10
上海市,713695 6
上海市,1059899 6
上海市,514725 6
上海市,213297 5
上海市,926069 5
```

可以发现结果相同,但是用python 编写的spark程序简单非常非常多

- 查询双11那天浏览次数前十的品牌 -- 和Hive作业对比结果
 - 1. 使用RDD编程

```
data=sc.textFile('file:///home/Hadoop/share-
files/million_user_log.csv')
data.cache()
  data=data.map(lambda x: list(x.split(',')))
data=data.filter(lambda x: x[7]=='0')
  data=data.map(lambda x:x[4])
lst=sorted(data.countByValue().items(), key= lambda x:
x[1],reverse=True)
print(lst[:10])
```

结果

之前使用Hive的结果:

```
OK
1360
        49151
3738
        10130
82
        9719
1446
        9426
6215
1214
        8470
5376
        8282
2276
        7990
         7808
1662
8235
        7661
```

2. 此外还可以用dataframe进行查询(pyspark不支持Dataset,因为python本身不是一种类型安全的语言)

```
#使用Dataframe+sparkSQL
from pyspark.sql.types import *
#如果使用默认反射推断会将全部数据推断为String,并且淘宝数据没有header,这里用编程
指定类型
schema = StructType([
StructField("user_id", StringType()),
StructField("item_id",StringType()),
StructField("cat_id", StringType()),
StructField("merchant_id", StringType()),
StructField("brand_id", StringType()),
StructField("month", StringType()),
StructField("day", StringType()),
StructField("action", StringType()),
StructField("age_range", StringType()),
StructField("gender", StringType()),
StructField("province", StringType())])
data1=spark.read.csv('file:///home/Hadoop/share-
files/million_user_log.csv',header=False,schema=schema)
data1.createOrReplaceTempView('taobao')
data1.show(5)
```

328862 406349 1280 2700 5476 11 11 2 6 0 台湾	user_id	item_id	cat_id	merchant_id	brand_id	month	day	action	age_range	gender	province
328862 807126 1181 1963 6109 11 11 0 1 0 上海市 328862 406349 1280 2700 5476 11 11 2 6 0 台湾						11	11	0	0	1	
						11	11	0	1	0	里庆巾 上海市
320002 400343 1200 2100 3410 11 11 0 0 2 0 N	328862 328862		1280 1280	2700 2700	5476 5476	11 11	11 11	2	6 6	0	台湾 甘肃

only showing top 5 rows

data2=spark.sql('select brand_id, count (action) actions from taobao
where action = 0 group by brand_id order by actions desc limit 10')
data2.show()

+	L
brand_id	actions
1360	49151
3738	10130
82	9719
1446	9426
6215	8568
1214	8470
5376	8282
2276	7990
1662	7808
8235	7661
+	++

参考教程: https://www.jianshu.com/p/cb0fec7a4f6d

3. 此外还可以是加载hiveContext然后运行SQL语句进行查询

```
from pyspark.sql import HiveContext
hive_context=HiveContext(sc)
hive_context.sql('select brand_id, count ( action ) actions from tUser
where action = 0 group by brand_id order by actions desc limit
10').show()
```